Clase 9: Tests de hipótesis

Lógica del test, errores, potencia, t-test, ANOVA y chi-cuadrado

Nicolás Sidicaro

Ciencia de Datos para Economía y Negocios | FCE-UBA

La pregunta

La pregunta

¿Existe una brecha salarial de género en Argentina?

Lo que se escucha

- *"Las mujeres ganan un 27% menos que los varones."* (titulares de prensa)
- *"A igual trabajo, igual salario."* (consigna de política pública)
- *"La brecha se cerró en sectores calificados."* (informes empresariales)

El problema

Son afirmaciones sobre la **población** (todos los trabajadores del país), pero los datos de los que salen son siempre una **muestra**. ¿Cómo pasamos de una diferencia observada en la muestra a una afirmación sobre la población?

Hoja de ruta de la clase

1. **Puente con Clase 7**: ¿qué distribuciones muestrales conocemos y cuáles no? ¿Qué hacemos cuando no las conocemos?
2. **Lógica del test**: H_0, H_1, p-valor, errores tipo I y II, potencia.
3. **Test t de una muestra**: ¿el ingreso medio supera un umbral?
4. **Test t de dos muestras**: ¿difieren los ingresos entre varones y mujeres? *(pregunta central)*
5. **ANOVA**: ¿difieren entre niveles educativos?
6. **Chi-cuadrado**: ¿la rama de actividad es independiente del género?
7. **¿Cuándo usar cada uno?** y reflexión final.

Repaso: distribuciones muestrales

¿Por qué no sabemos la distribución de nuestros estimadores?

El problema de fondo

Tenemos **una muestra** y queremos decir algo sobre la **población**. Para eso necesitamos saber cómo se comporta nuestro estimador ($\bar{X}$, $\hat{p}$, mediana, Gini, etc.) si repitiéramos el muestreo muchas veces: esa es su distribución muestral.

Pero...

En la vida real **no podemos repetir el muestreo**. Tomamos una muestra, no mil. Entonces: ¿cómo sabemos cuánto se equivoca nuestro estimador?

Dos caminos

1. Apoyarnos en **teoremas** que nos dicen la distribución muestral sin repetir el muestreo (TCL).
2. **Simular** el remuestreo computacionalmente (bootstrap).

Las que SÍ conocemos analíticamente

Gracias al Teorema Central del Límite

- **Media muestral** $\bar{X}$: $\bar{X} \dot{\sim} \mathcal{N}(\mu, \sigma/\sqrt{n})$ para n grande.
- **Proporción** $\hat{p}$: caso particular de la media $\Rightarrow \hat{p} \dot{\sim} \mathcal{N}(p, \sqrt{p(1-p)/n})$.
- **Diferencia de medias** $\bar{X}_1 - \bar{X}_2$: por propiedades de la Normal.
- **Coeficientes de regresión OLS**: bajo condiciones, también Normales.

La familia de distribuciones derivadas

A partir de la Normal aparecen:

- **t de Student**: media con σ desconocido (muestras chicas).
- **Chi-cuadrado** χ^2: suma de Normales al cuadrado (test de tablas).
- **F de Fisher**: cociente de varianzas (ANOVA).

Las que NO conocemos analíticamente

Estadísticos sin fórmula cerrada

- **Mediana**, percentiles, cuantiles en general.
- **Índice de Gini**, Theil, Atkinson.
- **Ratios** de cuantiles (P90/P10, P75/P25).
- **Máximos** y mínimos (teoría de valores extremos).
- **Estadísticos compuestos**: HHI, índices de segregación, etc.

¿Por qué no hay fórmula?

El TCL es un teorema sobre **sumas y promedios**. Cuando el estadístico *no* es una suma, o depende de colas, el teorema no aplica y no hay una forma cerrada para la distribución muestral.

La solución cuando no hay fórmula: bootstrap

La idea

Si no puedo repetir el muestreo de la población, **remuestreo con reemplazo** mi propia muestra B veces y uso eso como aproximación de la distribución muestral.

La receta

1. Tengo una muestra de tamaño n.
2. Saco una remuestra de tamaño n **con reemplazo**.
3. Calculo mi estadístico (mediana, Gini, lo que sea).
4. Repito B veces $\Rightarrow$ tengo B valores del estadístico.
5. Esa colección es mi distribución muestral aproximada.

Funciona porque...

La LGN garantiza que la muestra "se parece" a la población cuando n es grande. Entonces remuestrear de la muestra es *casi* como muestrear de la población.

¿Qué necesita el bootstrap para funcionar?

Condiciones sobre n (el tamaño de la muestra original)

- **Mínimo práctico**: $n \geq 30$–50.
- **Recomendable**: $n \geq 100$, sobre todo para estadísticos no lineales o distribuciones asimétricas.
- **Para colas e IC extremos**: $n \geq 500$–1000.

Condiciones sobre B (el número de remuestras)

- **Para un error estándar**: $B = 200$ suele alcanzar.
- **Para un IC al 95%**: $B \geq 1.000$.
- **Para p-valores y colas**: $B \geq 10.000$.

Y cuándo NO usarlo

Para estadísticos que dependen de **valores extremos** (máximo, mínimo): el bootstrap queda "pegado" contra esos topes y distorsiona la distribución.

Entonces: el terreno de hoy

En esta clase

Todos los tests que vamos a ver (t, ANOVA, chi^2) **usan distribuciones conocidas analíticamente** (t, F, χ^2). Son todas primas de la Normal y todas derivan del TCL.

La ventaja

No necesitamos simular nada: con fórmulas cerradas y tablas (o R) tenemos p-valores exactos.

El precio

Necesitamos que los supuestos se cumplan: muestras aleatorias, independencia, y normalidad (o n grande por TCL). Cuando esos supuestos fallan de manera importante $\rightarrow$ **bootstrap** o tests no paramétricos.

Una aclaración metodológica

¿Por qué no usamos PONDIIO en esta clase?

PONDIIO

Es el **ponderador de ingresos de la ocupación principal** de la EPH: indica a cuántas personas del universo representa cada persona encuestada, ajustado para estimar ingresos laborales.

Ponderar modifica la inferencia, no solo las medias

- La **estimación puntual** cambia (media ponderada $\neq$ media simple).
- El **error estándar** cambia: no es $\sigma/\sqrt{n}$ sino una fórmula con los pesos.
- Los **grados de libertad efectivos** se reducen (design effect de Kish).
- El n efectivo es menor que el n muestral.

Decisión pedagógica

Trabajamos **sin ponderar**, asumiendo que los asalariados registrados con ingreso horario positivo son representativos de esa subpoblación. Para inferencia correcta con ponderadores se usa el paquete `survey` (`svyttest`, `svyglm`, `svychisq`).

En el TP, para estadísticos descriptivos de ingresos, sí deben ponderar con PONDIIO.

Lógica del test

De estimar a decidir

Lo que sabemos hacer (Clase 7-8)

Dada una muestra, podemos:

- Estimar un parámetro: $\hat{p}$, $\bar{X}$.
- Cuantificar la incertidumbre: error estándar, IC.

Lo que todavía no sabemos

Tomar una **decisión** entre dos afirmaciones sobre la población. Por ejemplo:

- ¿La brecha de género es *distinta de cero* o pudo ser casualidad?
- ¿Los ingresos *difieren* entre niveles educativos?
- ¿La rama de actividad es *independiente* del género?

El test de hipótesis

Es un **procedimiento de decisión** con reglas claras sobre cuándo aceptamos y cuándo rechazamos una afirmación.

Las dos hipótesis

Hipótesis nula H_0

La hipótesis **conservadora**: "no pasa nada", "no hay efecto", "no hay diferencia". Es la que queremos *poner a prueba* (no la que queremos demostrar).

Hipótesis alternativa H_1

La hipótesis de **interés**: lo que querríamos probar. Generalmente afirma que hay un efecto, una diferencia, una asociación.

Analogía con la lógica jurídica

H_0: el acusado es **inocente**.

H_1: el acusado es **culpable**.

No decimos "es inocente" porque lo sea: lo decimos por defecto. Solo cambiamos de opinión si hay **evidencia suficiente** en contra.

Cómo se plantean para nuestra pregunta

Para la brecha de género en ingresos horarios

- H_0: $\mu_{\text{varón}} = \mu_{\text{mujer}}$ (no hay brecha)
- H_1: $\mu_{\text{varón}} \neq \mu_{\text{mujer}}$ (hay brecha, en algún sentido)

Dos colas vs una cola

- $H_1 : \mu_v \neq \mu_m$ es una hipótesis **bilateral** o de dos colas.
- $H_1 : \mu_v > \mu_m$ sería **unilateral**: solo rechazamos si los varones ganan más.
- Por defecto se usa bilateral, salvo que la teoría indique una dirección específica.

El estadístico de prueba

La pregunta operativa

¿Cuán lejos está mi estimación del valor que postula H_0?
Pero **medido en unidades de error estándar**, no en unidades de la variable.

Para una media

$$t = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$$

Si $\bar{X}$ está lejos de μ_0 *relativo al error estándar*, $|t|$ es grande y eso es evidencia contra H_0.

La clave

El estadístico convierte "cuán lejos estoy" en un número **comparable** contra una distribución de referencia (t, F, χ^2). Esa distribución nos dice qué valores son "esperables" si H_0 fuera cierta.

La distribución del estadístico bajo H_0

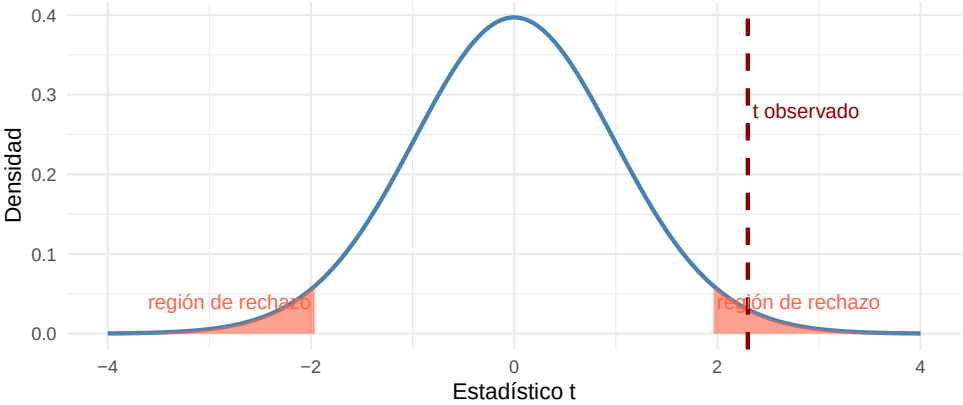

Si H_0 es cierta, el estadístico debería caer cerca de 0. Valores muy en las colas son raros bajo H_0: si cae ahí, es evidencia contra H_0.

El p-valor

Definición

El p-valor es la probabilidad de observar un estadístico **tan o más extremo** que el observado, *asumiendo que H_0 es verdadera*.

Cómo leerlo

- **p chico** (p.ej. $p = 0{,}01$): "si H_0 fuera cierta, sería muy raro haber visto estos datos" $\Rightarrow$ evidencia contra H_0.
- **p grande** (p.ej. $p = 0{,}40$): "los datos son compatibles con H_0" $\Rightarrow$ no rechazo.

Lo que el p-valor NO es

- NO es la probabilidad de que H_0 sea cierta.
- NO es la probabilidad de haberse equivocado.
- NO mide el tamaño del efecto.

Visualización del p-valor

El p-valor es el **área roja**: la probabilidad de caer "tan o más extremo" que lo observado bajo H_0.

La regla de decisión

El nivel de significancia α

Fijamos *de antemano* cuán raro tiene que ser un resultado para rechazar H_0.
Convención usual: $\alpha = 0{,}05$ (a veces 0,01 o 0,10).

La regla

- Si $p \leq \alpha \Rightarrow$ **rechazo** H_0.
- Si $p > \alpha \Rightarrow$ **no rechazo** H_0.

Cuidado con el vocabulario

Nunca decimos "**acepto** H_0". Decimos "no rechazo" o "no hay evidencia suficiente para rechazar". Es como en un juicio: "no culpable" $\neq$ "inocente probado".

Errores tipo I y II

Decisión	**Realidad**	
	H_0 verdadera	H_0 falsa
No rechazo H_0	✓ Correcto	**Error tipo II (β)**
Rechazo H_0	**Error tipo I (α)**	✓ Correcto

Interpretación

- **Error tipo I**: rechazar H_0 cuando era verdadera. Probabilidad $= \alpha$ (el nivel de significancia).
- **Error tipo II**: no rechazar H_0 cuando era falsa. Probabilidad $= \beta$.
- **Potencia** del test $= 1 - \beta =$ probabilidad de detectar un efecto cuando efectivamente existe.

¿Por qué fijamos α y no β?

La asimetría entre los dos errores

H_0 es la hipótesis conservadora: queremos protegernos contra rechazarla "por casualidad". Por eso controlamos directamente α.

Analogía

En un juicio penal:

- Error tipo I: condenar a un inocente. *Muy grave* $\Rightarrow$ exigimos evidencia fuerte (bajo α).
- Error tipo II: absolver a un culpable. Grave, pero *menos* que lo anterior.

Hay un trade-off

Bajar α (ser más exigentes) **sube** β (perdemos potencia).
Para reducir ambos simultáneamente: **aumentar** n.

¿Qué determina la potencia?

Cuatro factores

1. **Tamaño del efecto real**: diferencias grandes son más fáciles de detectar.
2. **Tamaño de la muestra** n: más datos $\Rightarrow$ más potencia.
3. **Variabilidad** (σ): más ruido $\Rightarrow$ menos potencia.
4. **Nivel** α: más permisivos (mayor α) $\Rightarrow$ más potencia (pero más falsos positivos).

Implicancia práctica

Antes de correr un experimento, los investigadores calculan la potencia para elegir n: si la potencia es muy baja, el estudio es una pérdida de tiempo (no vamos a detectar nada aunque exista).

Potencia vs tamaño de muestra: simulación

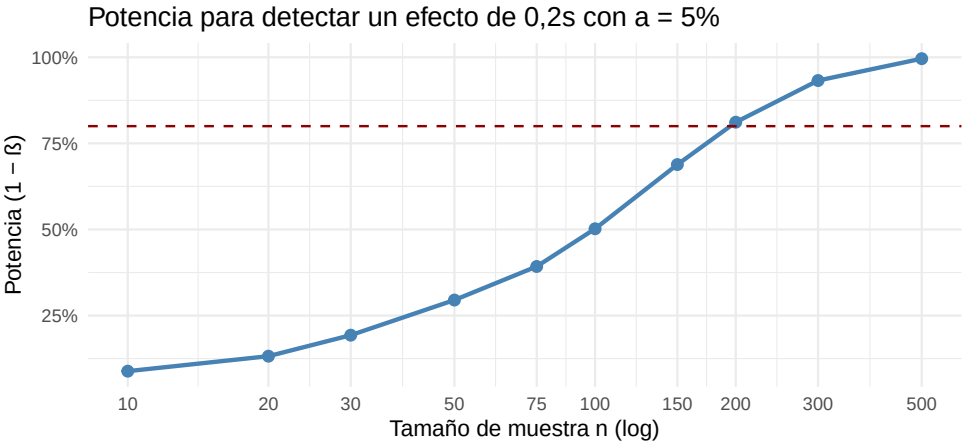

Con $n = 30$, apenas 31% de chance de detectar el efecto. Con $n = 200$, 80%. La línea roja marca el umbral convencional de potencia "adecuada".

Significancia estadística vs relevancia práctica

Una trampa común

Con muestras muy grandes, **cualquier diferencia** se vuelve estadísticamente significativa, aunque sea económicamente irrelevante.

Ejemplo

Si comparamos los ingresos de dos barrios con $n = 500.000$ en cada uno, una diferencia de \$50 por mes puede dar $p < 0{,}0001$. Estadísticamente significativo, económicamente trivial.

La lección

Siempre reportar:

- El **p-valor** (significancia estadística).
- El **tamaño del efecto** (magnitud de la diferencia).
- Un **IC** (rango plausible del efecto).

Los tres juntos cuentan la historia completa.

Test t de una muestra

Una pregunta acotada primero

¿Los asalariados registrados en Argentina ganan, en promedio, lo suficiente para estar sobre la línea de pobreza individual?

Valor de referencia

Línea de pobreza individual (LP) aproximada: \$350.000/mes.
Jornada completa $\approx$ 160 horas/mes.
$\Rightarrow$ **ingreso horario de referencia:** $\mu_0 \approx$ \$2.188/hora.

Las hipótesis

- H_0: $\mu = \mu_0$ (el ingreso horario medio es igual a la LP/hora)
- H_1: $\mu \neq \mu_0$ (difiere, sin especificar dirección)

Supuestos del t de una muestra

Lo que se necesita

1. **Independencia** entre observaciones (muestreo aleatorio).
2. **Normalidad** de la variable *o* n grande (TCL actúa sobre $\bar{X}$).
3. **Variabilidad finita**.

¿Por qué t y no z?

Si conociéramos σ poblacional, usaríamos $Z = (\bar{X} - \mu_0)/(\sigma/\sqrt{n})$ con distribución Normal. Pero σ **no la conocemos**: la estimamos con s. Eso agrega variabilidad y la distribución se vuelve **t de Student** con $n - 1$ grados de libertad.

Detalle

Para $n \geq 30$–50, la t es prácticamente indistinguible de la Normal. Con muestras chicas, la diferencia sí importa.

Aplicación

```
Test t de una muestra
---------------------
n = 11289
Media muestral (ing horario): $5.847/hora
Valor hipotético (mu_0)     : $2.188/hora
Diferencia                  : $3.660/hora
Estadístico t : 87.851
Grados de lib.: 11288
p-valor       : <0.0000000000000001
IC 95% media  : [$5.766 , $5.929]
```

Lectura del resultado

¿Qué concluimos?

- El p-valor es prácticamente cero: **rechazamos** H_0 al 5% (y al 1%).
- La media muestral está muy por encima de la LP/hora.
- El IC 95% no contiene a μ_0.

La conexión con el IC

Rechazar H_0 al 5% $\Leftrightarrow$ μ_0 **está fuera** del IC 95% de la media.
No rechazar $\Leftrightarrow$ μ_0 está adentro.

Es la **misma matemática** mirada desde otro ángulo.

Interpretación económica

En promedio, los asalariados registrados ganan significativamente por encima de la LP individual. Pero: esto es un **promedio**. Nada dice de la proporción bajo la línea.

Test t de dos muestras

La pregunta central de la clase

¿Difiere el ingreso horario medio entre varones y mujeres asalariados del sector privado registrado?

Las hipótesis

- H_0: $\mu_v = \mu_m$ (no hay brecha)
- H_1: $\mu_v \neq \mu_m$ (hay brecha)

Vista previa de los datos

Género	n	Media	Desvío	Mediana
Varón	5969	\$5.848	\$4.324	\$4.811
Mujer	5320	\$5.847	\$4.539	\$4.736

Supuestos y variante de Welch

Los supuestos clásicos

1. Independencia dentro y entre grupos (muestras aleatorias, grupos disjuntos).
2. Normalidad o n grande por grupo.
3. Homocedasticidad: $\sigma_v = \sigma_m$.

El supuesto 3 casi nunca se cumple

En datos reales las varianzas rara vez son iguales. Los desvíos por género en nuestra tabla ya lo muestran.

Solución: el test de Welch

- **No asume** varianzas iguales.
- Ajusta los grados de libertad con la fórmula de Welch-Satterthwaite.
- Es el **default** de `t.test()` en R.
- Es la recomendación actual de la literatura estadística.

Nota técnica: el estadístico de Welch es $t = (\bar{X}_v - \bar{X}_m)/\sqrt{s_v^2/n_v + s_m^2/n_m}$, *que no supone* $\sigma_v = \sigma_m$.

Aplicación

```
Test t de dos muestras (Welch)
------------------------------
n varones  : 5969  media: $5.848/h
n mujeres  : 5320  media: $5.847/h
Diferencia de medias (V - M): $2/h
Brecha relativa: 0% (respecto al ingreso masculino)
Estadístico t : 0.018
Grados de lib.: 10993.3
p-valor       : 0.986
IC 95% de la diferencia: [$-163 , $166]
```

Lectura del resultado

Qué concluimos

- No hay evidencia suficiente para rechazar H_0 al 5% de significatividad.
- La brecha en ingreso horario es no estadísticamente significativa.

Si hubiera dado que Rh0, sería grande la diferencia?

La significancia estadística diría que la brecha **no es cero**, pero no dice si es **relevante**. Para eso necesitamos:

- La brecha en porcentaje (tamaño del efecto relativo).
- El IC del efecto (qué tan precisa es la estimación).
- Una referencia económica (es mucho o poco contra qué?).

Alerta causal

La brecha existe. **No** probamos que sea "por" el género: puede haber variables omitidas (rama, horas, antigüedad, educación). Eso se lo chequeamos con regresión. Además, en este caso, la no diferencia significativa puede deberse al formato muestral. El viernes probamos con

Visualizando la brecha

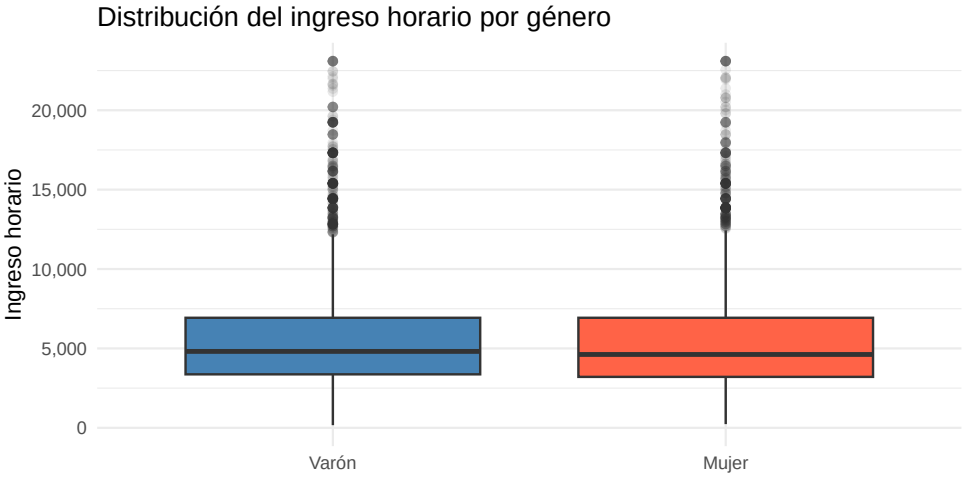

Las cajas muestran que casi no hay diferencia: la brecha de medias no pareciera ser estadísticamente real, pero la variabilidad *dentro* de cada grupo es mucho mayor que *entre* grupos.

Test t pareado

Cambiamos el tipo de comparación

Lo que hicimos hasta acá

Comparamos **dos grupos independientes**: varones y mujeres son personas *distintas*. Cada observación pertenece a un solo grupo.

Una situación distinta

A veces observamos **las mismas unidades en dos momentos** (o bajo dos condiciones):

- El mismo **país** en 2019 y en 2020.
- El mismo **paciente** antes y después de un tratamiento.
- La misma **empresa** pre- y post-política tributaria.
- El mismo **hogar** en la onda 1 y la onda 2 del panel de la EPH.

La diferencia clave

Las dos observaciones **no son independientes**: comparten todo lo que hace a la unidad (país rico o pobre, persona sana o enferma, empresa grande o chica). Ese vínculo hay que *aprovecharlo*, no ignorarlo.

La pregunta

¿Cambió significativamente el crecimiento del PBI per cápita entre 2019 y 2020 en los países del mundo?

Los datos

- Fuente: **World Development Indicators** (Banco Mundial), vía paquete `WDI`.
- Variable: crecimiento anual del PBI per cápita (%, a precios constantes).
- Unidades: países del mundo con dato en ambos años.
- Cada país tiene **dos observaciones**: una en 2019, otra en 2020.

Las hipótesis

Llamemos $d_i = Y_{i,2020} - Y_{i,2019}$ al cambio de cada país.

- H_0: $\mu_d = 0$ (en promedio, no hubo cambio)
- H_1: $\mu_d \neq 0$ (sí hubo cambio sistemático)

¿Por qué no usar un t-test de dos muestras?

Intento ingenuo

Tratar "el crecimiento en 2019" y "el crecimiento en 2020" como si fueran **dos muestras independientes** de países y hacer un Welch t-test.

Dos problemas

1. **Violación del supuesto de independencia**: Argentina-2019 y Argentina-2020 son la misma Argentina.
2. **Pérdida de potencia**: la variabilidad *entre países* (EE.UU. crece al 2%, Etiopía al 7%, Venezuela al -20%) es enorme y oculta el cambio común.

La idea del pareado

En vez de comparar los dos *conjuntos* de países, comparamos **el cambio dentro de cada país**. Cada país es su propio control: le restamos a sí mismo.

Mecánica del test pareado

El truco

El test t pareado no es un test nuevo: es un **t de una muestra** aplicado a las diferencias d_i.

Estadístico

$$t = \frac{\bar{d} - 0}{s_d/\sqrt{n}}$$

donde:

- $\bar{d}$: promedio de las diferencias por país.
- s_d: desvío estándar de las diferencias.
- n: cantidad de países (no $2n$).
- Grados de libertad: $n - 1$.

¿Por qué gana potencia?

s_d captura cuánto varía **el cambio** entre países, que suele ser mucho menor que cuánto varía el nivel entre países. Al restar, *cancelamos* toda la heterogeneidad permanente entre unidades.

Vista previa de los datos

n países	Media 2019	Media 2020	Media dif (d)	Desvío dif (sd)
208	1.71	-6.23	-7.94	7.89

Lectura preliminar

El crecimiento promedio cayó fuerte entre 2019 y 2020. La pregunta es si esa caída es estadísticamente distinta de cero, dada la variabilidad entre países.

Aplicación: los dos tests, en paralelo

```
Muestras independientes (INCORRECTO en este caso)
-------------------------------------------------
Diferencia de medias : -7.937 p.p.
Estadístico t        : -12.039
Grados de libertad   : 295.5
p-valor              : <0.0000000000000001
IC 95% de la dif.    : [-9.23 , -6.64]
Pareado (CORRECTO)
------------------
Media de las dif (d) : -7.937 p.p.
Estadístico t        : -14.516
Grados de libertad   : 207
p-valor              : <0.0000000000000001
IC 95% de la dif.    : [-9.02 , -6.86]
```

Lectura del resultado

Qué concluimos

- La caída promedio del crecimiento entre 2019 y 2020 fue de varios puntos porcentuales.
- El p-valor del test pareado es **prácticamente cero**: rechazamos H_0 con margen.
- El IC 95% no contiene al cero, y está *muy* lejos de él.

Comparando los dos tests

- Ambos dan significativo, pero el **estadístico t del pareado es mucho mayor** (en valor absoluto).
- El IC del pareado es **más angosto**: la estimación es más precisa.
- Parear reduce el ruido entre países y aumenta la *potencia*.

Interpretación

La pandemia COVID-19 produjo un shock negativo **sistemático y generalizado** al crecimiento: no fue sólo unos pocos países afectados, fue el mundo.

Visualizando el cambio país por país

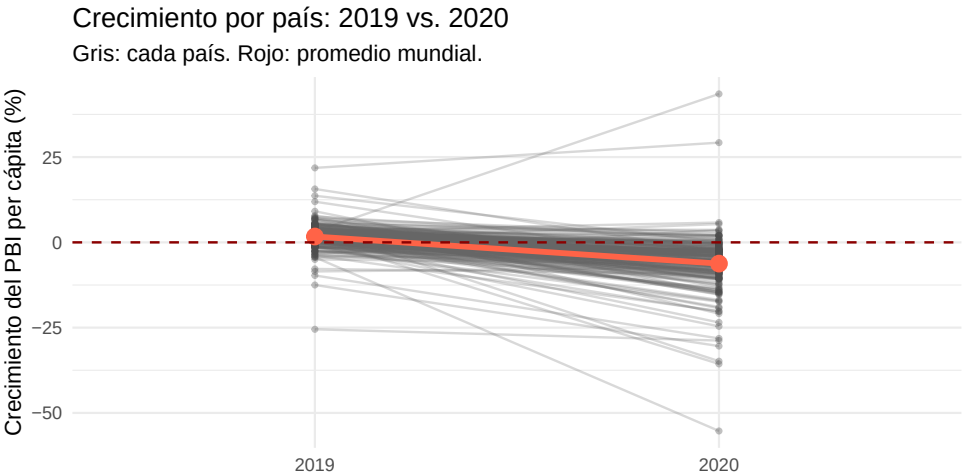

La enorme mayoría de las líneas bajan: casi ningún país quedó afuera del shock.

Distribución de las diferencias

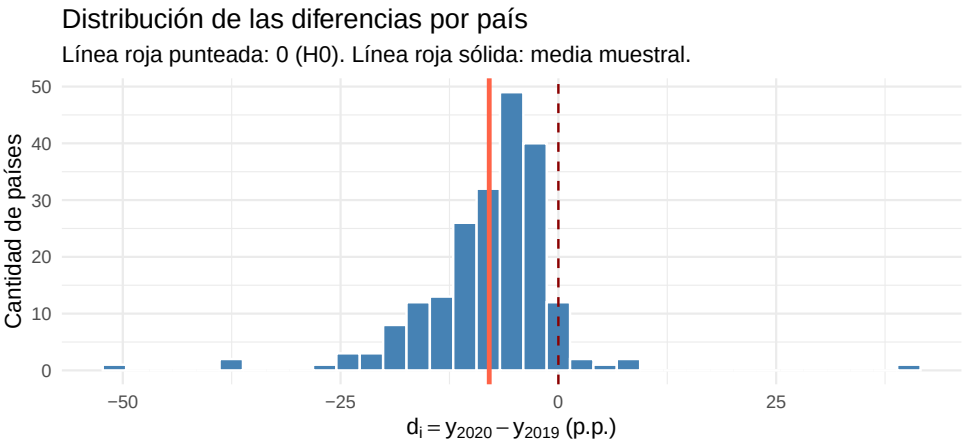

Lo que el test t pareado testea: ¿la distribución está **centrada en 0** o desplazada?

Supuestos del test pareado

Qué pide

1. Las **diferencias** d_i son independientes entre unidades (un país no afecta el cambio de otro). Supuesto discutible a nivel global, pero es lo que asumimos.
2. Las d_i son aproximadamente Normales, o n grande (TCL).

Lo que *no* pide

- **No** exige que las dos muestras sean independientes. Al contrario: el pareado aprovecha la dependencia.
- **No** exige que los niveles (Y_{2019}, Y_{2020}) sean Normales. Solo las diferencias.

Cuándo SÍ conviene parear

Siempre que exista un emparejamiento natural entre observaciones: antes/después, dos mediciones sobre la misma unidad, gemelos, hermanos, observaciones apareadas por diseño.

Resumen: pareado vs. dos muestras

	Dos muestras (Welch)	**Pareado**
Observaciones por unidad	1	2
Supuesto de independencia	Entre *todas*	Solo entre *unidades*
Estadístico	$(\bar{X}_1 - \bar{X}_2)/\sqrt{s_1^2/n_1 + s_2^2/n_2}$	$\bar{d}/(s_d/\sqrt{n})$
Grados de libertad	Welch-Satterthwaite	$n-1$
Ejemplo	Varones vs. mujeres	País 2019 vs. 2020

Regla mnemotécnica

¿Cada número "sabe" cuál es su par? Si sí $\Rightarrow$ pareado. Si no $\Rightarrow$ dos muestras.

ANOVA de un factor

La pregunta ahora tiene tres o más grupos

¿El ingreso horario difiere entre niveles educativos?

Los grupos

Cuatro niveles educativos:

1. Hasta secundario incompleto
2. Secundario completo
3. Superior incompleto
4. Superior completo

La pregunta formal

H_0: $\mu_1 = \mu_2 = \mu_3 = \mu_4$ (todas las medias son iguales)
H_1: al menos una μ_j difiere del resto.

Primer impulso: hacer todos los t-tests

¿Por qué no hacer 6 t-tests?

Con 4 grupos, las comparaciones posibles son:

$$\binom{4}{2} = 6 \text{ pares}$$

Podríamos correr cada par con un t-test.

Problema: inflación del error tipo I

Si cada test tiene $\alpha = 5\%$, la probabilidad de **al menos un** falso positivo entre los 6 es:

$$1 - (1 - 0{,}05)^6 \approx 26\%$$

5 veces más que el α nominal.

Primer impulso: hacer todos los t-tests

Con más grupos, peor

- 5 grupos $\rightarrow$ 10 comparaciones $\rightarrow$ α efectivo $\approx$ 40%
- 10 grupos $\rightarrow$ 45 comparaciones $\rightarrow$ α efectivo $\approx$ 90%

Simulación: ¿cuán grave es la inflación de α?

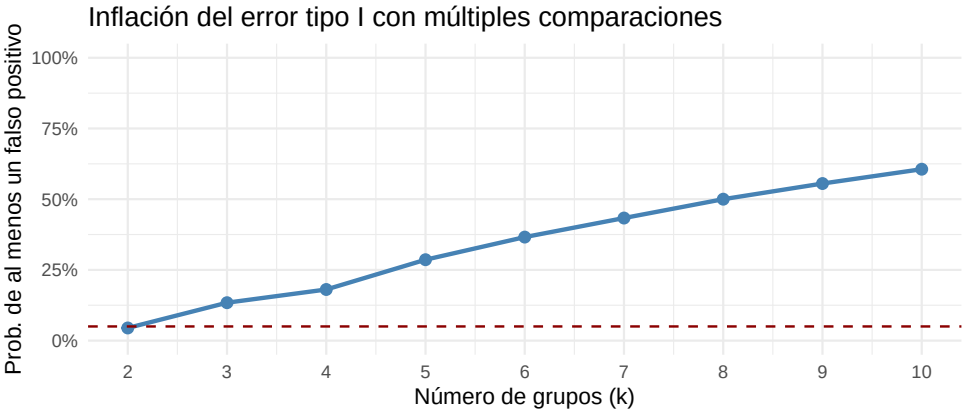

Línea roja: el $\alpha = 5\%$ nominal. Con 10 grupos hacer "todos los t-tests" equivale a testear al **60%** de error tipo I global.

La solución: ANOVA

Idea central

En lugar de muchos tests, **un único test global**: H_0 : todas las medias son iguales
H_1 : al menos una difiere

La intuición: comparar dos fuentes de variabilidad

- **Variabilidad entre grupos**: cuánto difieren las medias de los grupos entre sí.
- **Variabilidad dentro de grupos**: cuán dispersos están los individuos *dentro* de cada grupo.

La pregunta clave

¿La variabilidad **entre** grupos es *mucho más grande* que la variabilidad **dentro** de los grupos?

- Sí $\rightarrow$ los grupos son realmente distintos.
- No $\rightarrow$ las diferencias observadas son compatibles con el azar.

Descomposición de la varianza

La suma de cuadrados

$$\underbrace{\sum_{ij}(x_{ij}-\bar{x})^2}_{SC_{\text{total}}} = \underbrace{\sum_{j} n_j(\bar{x}_j-\bar{x})^2}_{SC_{\text{entre}}} + \underbrace{\sum_{ij}(x_{ij}-\bar{x}_j)^2}_{SC_{\text{dentro}}}$$

El estadístico F

$$F = \frac{SC_{\text{entre}}/(k-1)}{SC_{\text{dentro}}/(n-k)} = \frac{\text{varianza entre grupos}}{\text{varianza dentro de grupos}}$$

- Si F es grande $\rightarrow$ entre $\gg$ dentro $\rightarrow$ rechazo H_0.
- Si F es cercano a 1 $\rightarrow$ las dos fuentes son parecidas $\rightarrow$ no rechazo.

Distribución F bajo H_0

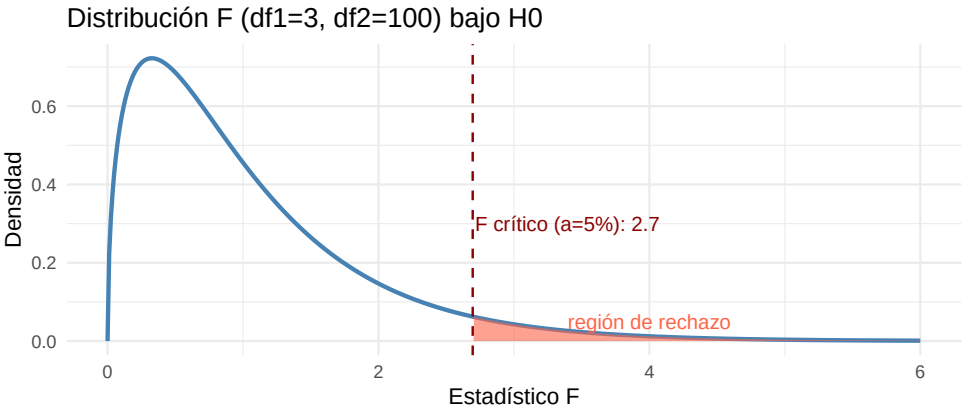

La F no es simétrica: es siempre no-negativa y está sesgada a la derecha. Solo rechazamos por valores grandes (cola derecha).

Supuestos de ANOVA

Los clásicos

1. Independencia dentro y entre grupos.
2. Normalidad dentro de cada grupo (o n_j grande).
3. Homocedasticidad: $\sigma_1 = \sigma_2 = \cdots = \sigma_k$.

Igual que con el t: la homocedasticidad rara vez se cumple

En datos económicos, los grupos con medias mayores suelen tener más dispersión.

Alternativas

- **Welch-ANOVA** (`oneway.test()` en R): análogo a Welch, no asume igualdad de varianzas.
- **Kruskal-Wallis**: versión no paramétrica (compara rangos, no medias).
- **Bootstrap**: siempre disponible.

Aplicación

Nivel educativo	n	Media	Desvío
Hasta secundario inc.	3044	$4.282	$3.409
Secundario completo	3814	$5.087	$3.290
Superior incompleto	1673	$5.848	$3.808
Superior completo	2758	$8.626	$5.691

```
Tabla ANOVA
-----------
          Df       Sum Sq      Mean Sq   F value   Pr(>F)
nivel_ed  3   3.1e+10   1.03e+10   612.49    <0.0000000000000001
Residuos  11285 1.9e+11   1.69e+07
```

Lectura del resultado

Qué nos dice la tabla ANOVA

- **F observado** es mucho mayor que 1 $\rightarrow$ la variabilidad entre grupos supera a la de dentro.
- **p-valor** muy chico $\rightarrow$ rechazamos H_0 al 5% (y al 1%).
- **Conclusión**: al menos un nivel educativo tiene ingreso horario medio distinto del resto.

Pero... ¿cuáles difieren?

ANOVA nos dice "hay diferencias", no **entre cuáles**. Para saberlo necesitamos un análisis post-hoc.

Post-hoc: Tukey HSD

¿Por qué necesitamos un test post-hoc?

El problema después del rechazo

F rechaza $\Rightarrow$ **alguna** diferencia hay. Pero:

- ¿Universitario vs secundario?
- ¿Todos los niveles entre sí?
- ¿Solo uno que "saca del promedio"?

No podemos volver a hacer "todos los t-tests"

Eso nos llevaría de vuelta al problema de inflación de α. Necesitamos una estrategia que **controle el error global** mientras hacemos comparaciones pareadas.

Tukey HSD (Honest Significant Difference)

- Es el test post-hoc **estándar** después de ANOVA.
- Compara todos los pares posibles.
- Ajusta los IC y p-valores para que el **error familiar** (global) siga siendo α.

La lógica de Tukey

Qué hace distinto

Tukey usa la distribución del **rango estudentizado*** en lugar de la t estándar. Esa distribución es más ancha, lo que produce IC más conservadores y controla el error global.

El resultado para cada par

Para cada comparación i vs j, Tukey devuelve:

- La **diferencia** de medias $\bar{x}_i - \bar{x}_j$.
- Un **IC ajustado** para esa diferencia.
- Un **p-valor ajustado**.

Regla de decisión

Si el IC de una diferencia **no contiene al 0**, esa pareja difiere significativamente.

**El rango estudentizado (q) es la diferencia entre el valor máximo y el mínimo de una muestra , medida en términos de desviaciones estándar muestrales*

Aplicación: Tukey HSD

Comparación	Dif.	IC inf.	IC sup.	p ajust.
SecCompl-SecInc	805	549	1.061	< 0.0000000000000001
SupInc-SecInc	1.567	1.245	1.888	< 0.0000000000000001
SupCompl-SecInc	4.345	4.067	4.622	< 0.0000000000000001
SupInc-SecCompl	762	452	1.071	0.00000000062
SupCompl-SecCompl	3.540	3.276	3.803	< 0.0000000000000001
SupCompl-SupInc	2.778	2.451	3.105	< 0.0000000000000001

Abreviaturas: SecInc = hasta secundario incompleto; SecCompl = secundario completo; SupInc = superior incompleto; SupCompl = superior completo.

Visualizando Tukey

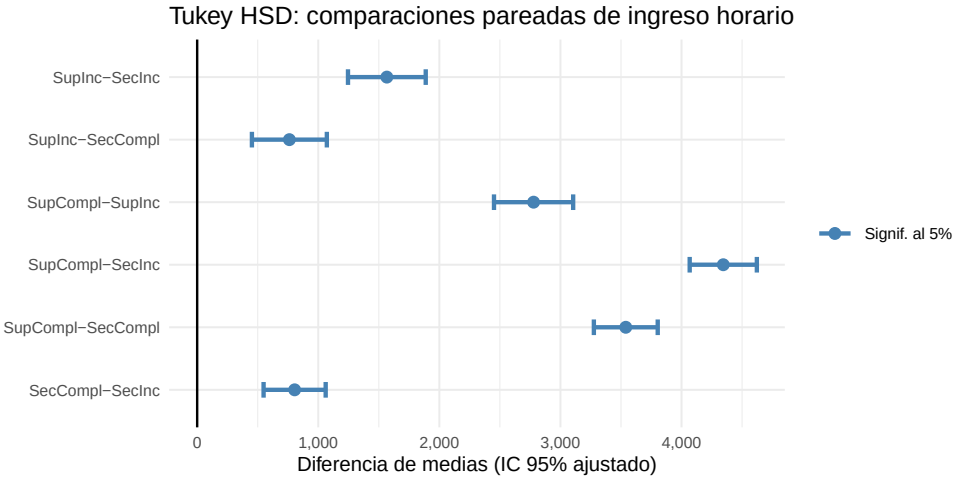

Los IC que **no cruzan el 0** indican diferencias significativas al 5% (con corrección por múltiples comparaciones).

Lectura de los resultados de Tukey

Patrones típicos que se observan

- Diferencias **grandes y significativas** al comparar superior completo contra los niveles más bajos.
- Diferencias **más pequeñas** entre niveles cercanos (secundario incompleto vs. completo).
- Algún par puede resultar **no significativo** (p.ej. superior incompleto vs secundario completo).

Mensaje estructural

La relación educación-ingresos **no es lineal ni suave**: los saltos más fuertes tienden a ocurrir al completar niveles, no al acumular años sueltos.

Recordatorio causal

Esto describe **diferencias de medias condicionales al nivel educativo**. No significa que cada año adicional de estudio "genere" ese ingreso: hay autoselección, habilidades no observadas, etc.

Test chi-cuadrado

Cambiamos de tipo de variable

Hasta acá

Todas las preguntas fueron sobre **medias** de una variable cuantitativa (ingreso horario).

Y si ambas variables son categóricas?

Reformulemos la brecha como **segregación ocupacional**:

¿La rama de actividad es independiente del género?

Las hipótesis

- H_0: género y rama son **independientes** (misma distribución por rama entre varones y mujeres).
- H_1: hay **asociación** (las mujeres se concentran en ciertas ramas y los varones en otras).

Tabla de contingencia: frecuencias observadas

Rama	Varón	Mujer	Total
Comercio	211	25	236
Industria y energía	967	289	1.256
Servicios a empresas	1.375	694	2.069
Servicios sociales y personales	951	2.962	3.913
Sum	3.504	3.970	7.474

Cada celda: cuántas personas de esa rama y ese género hay en la muestra.

Frecuencias esperadas bajo H_0

¿Qué significa "independientes"?

Si la rama de actividad *no dependiera* del género, entonces en cada rama las proporciones de varones y mujeres deberían ser iguales a las del total.

La fórmula

$$E_{ij} = \frac{(\text{total fila } i) \times (\text{total columna } j)}{\text{total general}}$$

Rama	Varón	Mujer
Comercio	111	125
Industria y energía	589	667
Servicios a empresas	970	1.099
Servicios sociales y personales	1.835	2.078

*Estas son las frecuencias que **esperaríamos** si rama y género fueran independientes.*

El estadístico chi-cuadrado

La idea

Medir cuán *lejos* están las frecuencias observadas de las esperadas bajo H_0:

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

Interpretación

- Si $O_{ij} \approx E_{ij}$ en todas las celdas $\rightarrow \chi^2$ chico $\rightarrow$ no rechazo.
- Si hay celdas con O_{ij} muy distintos de $E_{ij} \rightarrow \chi^2$ grande $\rightarrow$ rechazo.

Bajo H_0

χ^2 se distribuye como una χ^2 con $(r-1)(c-1)$ grados de libertad,
donde $r =$ filas y $c =$ columnas de la tabla.

Aplicación

```
Test chi-cuadrado de independencia
----------------------------------
Variables: rama de actividad x género
Dim. tabla: 4 x 2  (df = 3)
n total   : 7474

Chi-cuadrado observado: 1747.98
Grados de libertad    : 3
p-valor               : <0.0000000000000001
```

Conclusión

Rechazamos H_0: hay asociación entre género y rama de actividad. Varones y mujeres **no se distribuyen igual** entre sectores.

¿Dónde está la asociación? Residuos estandarizados

Rama	Varón	Mujer
Comercio	13.30	-13.30
Industria y energía	23.44	-23.44
Servicios a empresas	20.98	-20.98
Servicios sociales y personales	-41.00	41.00

Cómo leerlos

- **Residuo** $> +2$: esa celda tiene **muchas más** observaciones de las esperadas.
- **Residuo** $<$ -2: esa celda tiene **muchas menos**.
- $|\text{residuo}| < 2$: la celda se ajusta a lo esperado bajo independencia.

Los residuos estandarizados permiten identificar qué celdas específicas contribuyen a la asociación.

Visualizando la asociación

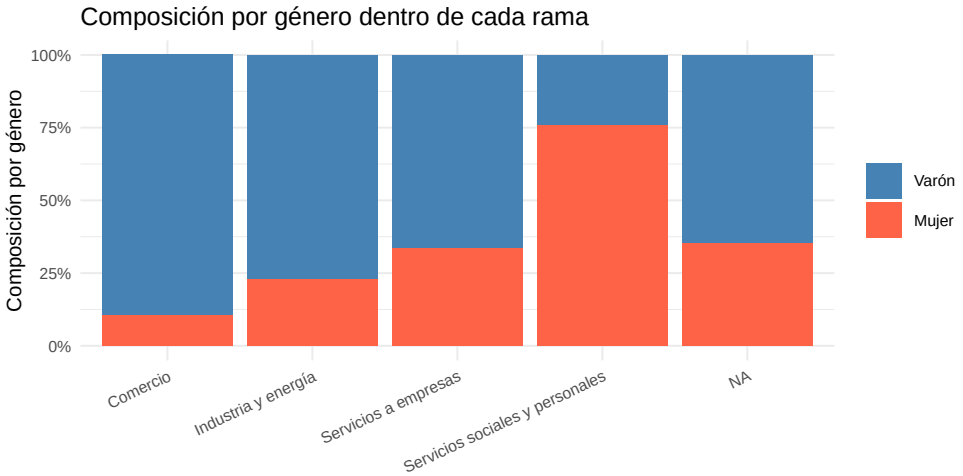

Si rama y género fueran independientes, todas las barras tendrían la misma composición. Lo que vemos es **segregación ocupacional**.

Repensemos el test de diferencia de medias

1. Nos dio que no había diferencias significativas
2. Sin embargo, sí hay diferencias en los sectores
3. En servicios sociales y personales, se incluyen tareas de cuidado y serv. doméstico
4. Suelen tener menos horas de trabajo que otros trabajos
5. Entonces, podríamos repetir el Test pero con el ingreso total, en lugar del horario
6. Queda para el viernes

Supuestos del chi-cuadrado

Lo que pide el test

1. **Independencia** entre observaciones.
2. **Conteos esperados suficientes** en cada celda: la regla práctica es $E_{ij} \geq 5$ en el 80% de las celdas, y ninguno < 1.

Cuando los conteos esperados son chicos

- **Fusionar categorías** (cuando tiene sentido sustantivo).
- **Test exacto de Fisher** para tablas 2×2 con n chico.
- **Simulación de Monte Carlo** (`simulate.p.value = TRUE`) en R.

Chi-cuadrado también sirve para bondad de ajuste

Otra pregunta posible

¿Los datos observados son compatibles con una distribución **teórica**?
H_0: la distribución observada sigue la teórica.
H_1: difiere.

Ejemplos típicos

- ¿La distribución de la EPH por región coincide con la del censo poblacional?
- ¿La distribución de primeros dígitos sigue la ley de Benford? (detección de fraude)
- ¿Los residuos de un modelo son Normales?

Misma fórmula

$\chi^2 = \sum(O - E)^2/E$, pero E viene de la distribución teórica, no del producto de marginales.
En R: `chisq.test(x, p = p_teorica)`.

¿Cuándo usar cada uno?

Árbol de decisión

Pregunta	Variable Y	Variable X	Test
Una media vs. un valor	Cuantitativa	–	**t de una muestra**
Dos medias	Cuantitativa	Binaria	**t de dos muestras**
Tres o más medias	Cuantitativa	Categórica (k grupos)	**ANOVA**
¿Cuáles grupos difieren?	Cuantitativa	Categórica (k grupos)	**Tukey HSD**
Independencia	Categórica	Categórica	**Chi-cuadrado**
Bondad de ajuste	Categórica	Distribución teórica	**Chi-cuadrado**

Todo esto usa distribuciones conocidas (t, F, χ^2)

Todos están conectados con la Normal vía el TCL. Por eso podemos tener p-valores exactos (o casi) con fórmulas cerradas.

Qué hacer cuando los supuestos fallan

Normalidad o n chico

- Test de **Wilcoxon** (una o dos muestras): versión no paramétrica del t.
- **Kruskal-Wallis**: versión no paramétrica de ANOVA.

Homocedasticidad (varianzas distintas)

- **Welch t-test** (default en R).
- **Welch-ANOVA**: `oneway.test()`.

Estadísticos "raros" sin distribución conocida

- **Bootstrap**: IC y tests para medianas, Gini, ratios, etc.
- **Tests de permutación**: para diferencias de cualquier estadístico entre grupos.

Un esqueleto común

Todo test de hipótesis sigue el mismo esqueleto

1. Planteo H_0 y H_1.
2. Elijo un estadístico de prueba.
3. Conozco (analítica o computacionalmente) su distribución bajo H_0.
4. Calculo el p-valor.
5. Comparo con α y decido.

Lo único que cambia

- El estadístico (t, F, χ^2, bootstrap...).
- La distribución de referencia.

La **lógica** es idéntica.