

Clase 18: Visualización - Parte 1

¿Cómo visualizar para analizar?

Nicolás Sidicaro

Ciencia de Datos para Economía y Negocios | FCE-UBA

Clase 18 — 26 de mayo de 2026

Apertura

Arrancamos a visualizar

- **Hoy** (clase 18): ¿qué gráfico para qué pregunta? Sin código.
- Clase 19: cómo hacer cada uno con ggplot2.
- Clase 20: principios de diseño y storytelling (ejemplos de Our World in Data - Insights).
- Clase 21: editorialización avanzada en R (cómo hacemos los gráficos de Owid).


Hoy nos enfocamos en **análisis exploratorio**: gráficos para *entender* datos, no para comunicarlos a otros.

El espíritu de hoy

- Una estadística (media, correlación, R^2) **resume**.
- Un gráfico **muestra**.
- Resumir bien requiere haber visto primero.
- **Elegir el gráfico es un acto de análisis.**


Ocho distribuciones, una sola estadística

Idéntica media, varianza y correlación. Solo el gráfico las distingue.



El cuarteto de Anscombe

Mismo promedio de X y Y, correlación y recta de regresión. Cuatro fenómenos distintos.



¿Qué vemos hoy?

Cada gráfico que veamos hoy responde a una **pregunta analítica**.

La pregunta no es “¿cuál se ve más lindo?” sino “¿cuál **muestra** lo que necesito ver?”.

- ❶ ¿Qué forma tiene esta variable?
- ❷ ¿Qué pasa en el tiempo?
- ❸ ¿Cómo se relacionan dos variables continuas?
- ❹ ¿Cómo comparo grupos o entidades?

Las próximas clases

- Estética, paletas de color, fuentes.
- Storytelling, anotaciones, títulos editorializados.
- Cómo escribir el código.
- Principios de Tufte, data-ink ratio.

Bloque 1: ¿Qué forma tiene esta variable?

La pregunta


Tengo una variable continua. ¿Cómo se distribuye?

Seis herramientas que responden la misma pregunta, mostrando cosas distintas:

- Histograma, densidad, ECDF.
- Boxplot, violín, ridgeline.

Veamos qué muestra y qué oculta cada una.

Histograma: el default




Muestra **frecuencias por intervalos**. ¿Qué pasa si cambiamos el ancho del intervalo?

El problema del binning

Mismos datos, tres elecciones de binning


Bin chico: ruido. Bin grande: oculta forma. No hay 'bin correcto'.



Densidad: suaviza el problema, no lo elimina

Densidad: el bin se reemplaza por el bandwidth


Mismo problema con otro nombre. La decisión sigue ahí.



ECDF: cuando no querés decidir nada

Función de distribución acumulada empírica (ECDF)

Cada punto: $P(X = x)$. Cuantiles directos del eje Y. Sin binning ni bandwidth.




- Menos “linda” pero más fiel al dato.
- Lee mediana y cuantiles directamente.

Boxplot: el clásico

Esperanza de vida 2007 — boxplot


Mediana, IQR, bigotes, outliers. Resumen poderoso en poco espacio.



Lo que el boxplot oculta

Cuatro distribuciones radicalmente distintas...


...con boxplots prácticamente idénticos.



Lo que el violín muestra

Las mismas cuatro distribuciones, ahora en violín


Bimodalidad, uniformidad y asimetría: invisibles en el boxplot.



Strip plot: cuando hay pocas observaciones

Esperanza de vida 2007 — países de las Américas (N = 25)


Con N chico, mostrar cada observación es honesto. El boxplot solo no alcanza.



Ridgeline plot: muchas distribuciones a la vez

Esperanza de vida por continente, 2007

Forma, nivel y dispersión de muchos grupos en una sola vista.



Resumen del bloque 1

Gráfico	Muestra	Cuidado con
Histograma	Frecuencias por intervalos	Elección del bin
Densidad	Forma suavizada	Elección del bandwidth
ECDF	Cuantiles directos	Menos intuitiva al inicio
Boxplot	Resúmenes (mediana, IQR, outliers)	Oculto forma
Violín	Forma + resúmenes	Necesita N razonable
Ridgeline	Muchos grupos comparados	Pierde precisión si hay muchísimos

*Regla: **nunca confíes solo en un boxplot** si no viste antes la forma.*

Bloque 2: ¿Qué pasa en el tiempo?

La pregunta

Tengo variables que cambian en el tiempo. ¿Qué muestro?

La línea es default. Y suele estar bien. Pero hay seis situaciones donde **la línea no alcanza**.

Situación 1: pocos momentos, muchas entidades

Esperanza de vida en las Américas: 1977 vs 2007

Slope chart: el ojo sigue trayectorias. Quién subió, quién se quedó.




¿Cuándo usar slope chart?

- **Pocos puntos** en el tiempo (2-3).
- Series que cambian muy poco en el tiempo
- **Muchas entidades** (países, sectores, regiones).
- El interés está en el **cambio**, no en el nivel.
- Si una entidad rompe el patrón, se ve sola.

Situación 2: escalas muy distintas → indexar

PIB per cápita indexado (1962 = 100)

Comparar crecimiento entre países con niveles muy distintos.




- Trade-off: perdés la información de **niveles**.
- La elección de la base condiciona la lectura. No es lo mismo el año base que se elegido.

Situación 3: muchas series → small multiples

20 países asiáticos superpuestos: spaghetti chart


Más de 5 series superpuestas: ilegible.



Small multiples: el mismo dato, otra disposición

Mismas 20 series, una grilla por país

Ejes compartidos: comparación por inspección visual.




- Hasta 5 series: superposición funciona.
- Más de 5: small multiples.
- Híbrido útil: resaltar 1-2 en color + el resto en gris

Situación 4: trayectoria conjunta de dos variables

Corea del Sur: trayectoria PIB pc vs esperanza de vida (1952–2007)

Connected scatterplot: dos variables en el tiempo, juntas.




Aplicación clásica en economía: **curva de Phillips** (inflación vs desempleo).

Situación 5: efecto de un evento

Esperanza de vida en Europa del Este — tiempo relativo al evento

Eje X centrado en $t=0$ (1992). Línea roja: promedio de la región.




- Variante con control: tratados vs no tratados alrededor del evento.

Situación 6: brecha entre dos momentos

Esperanza de vida en las Américas: 1957 -> 2007

Dumbbell plot: rojo = inicio, azul = final. Longitud = magnitud del avance.



Slope vs dumbbell: ¿cuándo cada uno?

Pregunta principal	Gráfico
¿Quién subió, quién bajó?	Slope
¿Hay cruces entre entidades?	Slope
¿Qué tan grande es la brecha?	Dumbbell
¿Cómo ordeno las entidades?	Dumbbell

Resumen del bloque 2

Situación	Gráfico
Pocos momentos, muchas entidades	Slope chart
Escalas distintas, foco en crecimiento	Serie indexada
> 5 series	Small multiples
Trayectoria conjunta de dos variables	Connected scatter
Antes/después de un shock	Event study
Brecha entre dos momentos	Dumbbell

Bloque 3: ¿Cómo se relacionan dos continuas?

La pregunta


Tengo dos variables continuas. ¿Cómo se relacionan?

El scatter es default. Pero hay variantes que **dicen más** según lo que busques.

Scatter con cuadrantes: clasificar entidades

PIB per cápita y esperanza de vida — cuatro cuadrantes


Líneas en la mediana. Cada cuadrante define un tipo de país.



La elección de los cortes es análisis

- Mediana, promedio, valor de referencia (un país, un umbral político): cada elección define un grupo distinto.
- Es la decisión más importante del gráfico.
- Definir la elección de las líneas es definir la tipología.

Lectura rápida: escala logarítmica




- **Cuándo conviene:** cuando los datos cubren varios órdenes de magnitud, la distribución es muy sesgada, o la relación entre las variables es **multiplicativa** (no aditiva).
- **Cómo se lee:** cada tick es una **multiplicación**, no una suma. Distancia visual igual = proporción de cambio igual. De \$500 a \$5.000 ocupa el mismo espacio que de \$5.000 a \$50.000.
- **En el ejemplo:** en lineal, los países pobres se aplastan contra el eje y se ve un “codo”; en log, la nube se despliega y aparece una relación casi lineal (la curva de Preston “enderezada”).
- **Pendientes en log son economía pura:** log-lineal $\rightarrow$ cambio porcentual de Y por unidad de X; log-log $\rightarrow$ elasticidad (% de Y por % de X).

Bubble chart: agregar una tercera dimensión

Esperanza de vida vs PIB pc, 2007 — tamaño = población

Estilo Hans Rosling: tres variables en una sola vista.




Cuidados con los bubbles

- El ojo percibe **área**, no radio. Si mapeás al radio, exagerás.
- Si la tercera variable es discreta con pocos valores → mejor color, no tamaño.
- Si hay muchos puntos que se superponen → ilegible.
- Si el rango de tamaños es muy amplio → puntos diminutos vs gigantes que dominan.

Smoother: cuando la relación no es lineal

Curva de Preston: esperanza de vida vs PIB per cápita, 2007

Smoother (loess): detecta no-linealidades sin imponer forma funcional.



Cóncava, con rendimientos decrecientes: una recta hubiera ocultado la forma.

Resumen del bloque 3

Necesidad	Gráfico
Clasificar entidades en grupos	Scatter + cuadrantes
Agregar tercera variable continua	Bubble chart
Ver no-linealidades	Scatter + smoother
Distribución conjunta + marginales	Scatter + marginales

Bloque 4: Comparaciones, rankings y composición


La pregunta

Quiero comparar entidades, o ver cómo se descompone un total.

Ranking con barras (el default)

Esperanza de vida en las Américas, 2007


Barras horizontales ordenadas. Funciona... pero satura visualmente.



Lollipop: menos tinta, igual claridad

Misma información, otra geometría

Lollipop: la línea fina + el punto pesan menos visualmente que la barra llena.




- Cleveland dot plot: igual sin la línea.
- **Siempre** ordenar por valor, salvo que el orden tenga otra lógica (alfabético, geográfico).

Composición: stacked bar relativo (100%)


Composición de países por nivel de PIB pc en el tiempo

Cada barra suma 100%. Compara composición entre grupos.



- Limitación: solo el segmento de la base se lee con precisión. Los demás “flotan”.

Mosaic plot: tabla cruzada visual



- Áreas proporcionales a frecuencias conjuntas.
- Muestra marginales y condicionales a la vez.

Resumen del bloque 4

Necesidad	Gráfico
Rankear muchas entidades	Lollipop / Cleveland
Comparar composición entre grupos	Stacked bar relativo
Relación entre dos categóricas	Mosaic plot

Cierre

Las cuatro preguntas, los gráficos

Pregunta	Gráficos clave
¿Qué forma tiene esta variable?	Densidad, ECDF, boxplot, violín, ridgeline
¿Qué pasa en el tiempo?	Línea, slope, indexada, small multiples, connected, event, dumbbell
¿Cómo se relacionan dos cont.?	Scatter, cuadrantes, bubble, smoother, marginales
¿Cómo comparo grupos?	Lollipop, stacked bar relativo, mosaic

La idea principal

*Elegir un gráfico **es** análisis.*


- Cada gráfico responde a una pregunta distinta.
- Cada uno muestra algo y oculta algo.
- No hay “el mejor gráfico”. Hay el mejor para esta pregunta.

Antes de hacer un gráfico, hacete dos preguntas:

- 1 ¿**Qué quiero ver?** (la pregunta analítica)
- 2 ¿**Qué quiero que el gráfico muestre**, y qué estoy dispuesto a que oculte?

Bloque extra: validar con gráficos

Q-Q plot: cómo se construye




Construcción paso a paso:

- 1 **Ordenar** los datos de menor a mayor: $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$.
- 2 Calcular **cuantiles teóricos** de la distribución de referencia (por default, normal estándar): $q_i = \Phi^{-1}((i - 0.5)/n)$. Es decir, "¿qué valor deja $(i - 0.5)/n$ de probabilidad por debajo, si la distribución fuera normal?".
- 3 **Graficar** los pares $(q_i, x_{(i)})$.

La recta de referencia: si los datos siguen $N(\mu, \sigma^2)$, entonces $x_{(i)} \approx \mu + \sigma \cdot q_i$. Por eso esperamos puntos sobre una recta con **intercepto** μ y **pendiente** σ .


Q-Q plot: cómo se leen los desvíos



- **Normal:** los puntos abrazan la recta. Lo que buscamos al chequear residuos.
- **Sesgo derecho** (asimetría positiva): la cola superior se **levanta** sobre la recta. Típico de ingresos, riqueza, precios, capitalización bursátil.
- **Sesgo izquierdo:** la cola inferior **cae** por debajo de la recta. Menos común en datos económicos.
- **Colas pesadas:** las dos colas se separan (extremos arriba y abajo de la recta). Más outliers de los que predice la normal. Típico de **retornos financieros**.

Regla práctica con N chico: incluso datos verdaderamente normales muestran desvíos en las puntas. No sobre-interpretar con $n < 30$.

Observado vs Predicho: cómo se construye




Construcción:

- 1 Para cada observación i , obtener el valor **predicho** $\hat{y}_i$ del modelo y el **observado** y_i .
- 2 Graficar los pares $(\hat{y}_i, y_i)$ con los **dos ejes en la misma escala** (`coord_equal()`).
- 3 Dibujar la **línea de 45°** ($y = x$) como referencia ideal.

Tres lecturas inmediatas:


- **Calidad del ajuste:** qué tan apretada está la nube alrededor de la recta. Es una versión visual del R^2 .
- **Rango cubierto:** si los predichos sólo van de 60 a 75 pero los observados de 40 a 85, el modelo está **comprimiendo** la variable.
- **Asimetría de errores:** ¿erra más para arriba o más para abajo?

Observado vs Predicho: patrones diagnósticos



- **Buen ajuste:** nube angosta alrededor de la recta, dispersión uniforme. Sin patrones sistemáticos.
- **Sesgo constante:** nube paralela a la recta pero **corrida**. El modelo erra siempre en la misma dirección — típicamente un intercepto mal estimado o una variable omitida con media no nula.
- **No-linealidad:** forma de “banana”. El modelo lineal no captura la relación verdadera. Solución: agregar transformación (log, cuadrático) o usar otro tipo de modelo.
- **Heteroscedasticidad:** la dispersión crece (o decrece) con el predicho. La varianza del error no es constante. Solución: errores robustos, transformación, modelo ponderado.

Doble ECDF: ¿dos grupos tienen la misma distribución?




- **Qué hace:** superpone las distribuciones acumuladas empíricas de dos (o más) grupos.
- **Referencia:** que las curvas se solapen → distribuciones iguales.

Series temporales: aplicación de la escala log

PIB per cápita 1952-2007 en escala logarítmica

PIB per cápita 1952-2007 (escala log10)

Pendiente = tasa de crecimiento. Líneas paralelas = crecen al mismo ritmo.



Interpretación: ¿qué nos dice esta vista?


Lectura por país:

- **EE.UU.:** pendiente moderada y muy estable. Crece a una tasa aproximadamente constante ($\sim 2\%$ anual) durante 55 años. Es la “frontera” tecnológica.
- **Corea del Sur:** pendiente **muy empinada** y sostenida. Caso clásico de **convergencia**: empieza más pobre que Argentina y termina muy por encima de Brasil. La aceleración arranca en los años 60.
- **Argentina:** pendiente baja, con varios quiebres. Crece, pero **más lento que EE.UU.**: hay divergencia sostenida. Es difícil ver los detalles de cada crisis a esta resolución, pero la pendiente promedio es menor.
- **Brasil:** pendiente algo mayor que Argentina hasta los 80, luego se aplan.
- **Chile:** pendiente que **se acelera** visiblemente desde mediados de los 80.

Por qué la escala log es indispensable acá:

- En escala lineal, Argentina y EE.UU. terminan a \$10k y \$42k respectivamente: la diferencia es 4x. Pero en 1952, era \$5k y \$13k: diferencia de 2,6x. La divergencia es relativa, no absoluta.
- **En log, la pendiente es la tasa de crecimiento.** Dos países que crecen al mismo ritmo se ven como **líneas paralelas**, sin importar de qué nivel partan.
- La regla mnemotécnica: *“si pensás en porcentajes, graficá en log”*.

PIB per cápita relativo a EE.UU. (= 100%)




- Línea **horizontal** = mantiene la distancia con EE.UU.; línea que **sube** = converge; línea que **baja** = diverge.
- **Argentina** en 1952: ~50% del PIB pc de EE.UU. En 2007: ~25%. Casi se reduce a la mitad. Divergencia clara.
- **Corea del Sur** en 1952: <10%. En 2007: >50%. Convergencia espectacular, casi al revés que Argentina.
- **Cuándo usar este gráfico**: cuando lo importante es la **posición relativa a un benchmark**, no el nivel absoluto.
Ejemplos: comparaciones internacionales contra la frontera tecnológica, brechas regionales, distancia a un objetivo de política.

Variación con peso: bubble chart categórico

Cambio en PIB per cápita 1977 → 1987, Américas

Tamaño = población en 1987. La 'década perdida' visible país por país.



El gráfico anterior: lectura y cuándo usarlo

Qué codifica (cuatro variables a la vez):

- **Eje X:** variable categórica (acá países; en el original que vimos, sectores económicos).
- **Eje Y:** variable numérica de interés (cambio %, tasa, performance).
- **Tamaño:** peso o importancia relativa (población, % del empleo, share de mercado, peso en el PIB).
- **Color:** signo o grupo categórico (subió/bajó, ganó/perdió, ganador/perdedor).

Cuándo conviene usarlo:

- Reportes de **coyuntura económica sectorial** (como el original: actividad y empleo por sector).
- Comparar performance de muchas entidades teniendo en cuenta su tamaño relativo —no es lo mismo que caiga 10% un sector que pesa 2% del empleo que uno que pesa 25%.
- Cuando una sola dimensión (¿quién subió?) no alcanza, y querés mostrar también “¿cuánto pesa?”.

Cuidados:

- El ojo percibe **área**, no radio. Usar `scale_size_area()` para que el área (no el radio) sea proporcional a la variable de peso.
- Con muchas categorías se vuelve denso. **Ordenar por valor** (no alfabético) ayuda a leerlo de izquierda a derecha.
- El color por signo es informativo pero **redundante** con la posición en el eje Y. Usarlo si querés reforzar grupos discretos, no como decoración.